



۱۶ اسفند ماه ۱۴۰۲



دانشگاه آزاد اسلامی واحد مراغه
با همکاری دبیرخانه برنامه‌های علمی استان کرمان برگزار می‌کند

دوین کنفرانس ملی تحولات نوین در مطالعات ملی اقتصادی و حسابداری

پیش بینی قیمت سهام در بازار بورس تهران با رویکرد هوش مصنوعی

مصطفی شایگانی

کارشناسی ارشد مدیریت مالی، دانشکده مدیریت و حسابداری، دانشکدگان فارابی دانشگاه تهران، قم، ایران

shaygani@ut.ac.ir

عسگر نوربخش

استادیار، گروه مدیریت مالی، دانشکده مدیریت و حسابداری، دانشکدگان فارابی دانشگاه تهران، قم، ایران، نویسنده مسئول

anoorbakhsh@ut.ac.ir

۱- چکیده

زمینه و هدف: هدف اصلی این پژوهش پیش بینی قیمت سهام با استفاده از دو نوع شبکه عصبی در بازار بورس تهران است. این مدل‌ها را از منظر دقت پیش‌بینی کنندگی به طور مطلق و نسبی بررسی می‌کنیم. با توجه به اینکه شبکه‌های عصبی بازگشتی عموماً در پیش‌بینی داده‌های سری زمانی توانایی خوبی دارند، اما شبکه‌ی عصبی پیچشی عمدتاً برای کاربردهایی چون بینایی کامپیوتر استفاده می‌شوند.

روش تحقیق: برای انجام این پژوهش از زبان پایتون در ویرایشگر VS code استفاده شده است. جامعه آماری این پژوهش بورس اوراق بهادار تهران می‌باشد. حجم نمونه آماری این پژوهش داده‌های سه نماد بورس اوراق بهادار تهران به شرح ایرانخودرو، البرز دارو و توسعه معادن روی ایران می‌باشد. در این پژوهش از هشت ویژگی قیمت در چارچوب زمانی روزانه از تاریخ ۱۳۸۰ تا تاریخ ۱۴۰۰ استفاده می‌شود که شامل بالاترین قیمت، پایین‌ترین قیمت، قیمت بسته شدن، قیمت باز شدن، ارزش معاملات، حجم معاملات، اختلاف قیمت بسته شدن دو روز متوالی، بازده روزانه. برای ارزیابی عملکرد مدل‌ها از سه معیار خطای میانگین خطای مطلق، ریشه میانگین مربعات خطا و ضریب تعیین استفاده شده است

یافته‌ها: نتایج نشان می‌دهد که مدل شبکه عصبی پیچشی توانایی پیش‌بینی با دقت خوبی را دارا می‌باشند. شبکه‌های عصبی بازگشتی از بهترین نوع شبکه‌ها برای پیش‌بینی قیمت هستند، اما نتایج نشان می‌دهد که شبکه عصبی پیچشی عملکرد بهتری از شبکه عصبی حافظه کوتاه مدت ماندگار داشته است.

نتیجه‌گیری: نتایجی که یافته‌های این پژوهش نشان می‌دهد، این است که مدل‌های یادگیری عمیق در صورتی که در انتخاب ویژگی‌هایی (متغیرهای مستقل) که بتوانند بیشترین میزان معناداری را در تفسیر علل فراز و فرودهای قیمت را دوره‌های رونق و رکود بازار بیان کند، قابلیت و توانایی پیش‌بینی قیمت، با دقت قابل قبول دارا می‌باشند.

کلیدواژه‌ها: شبکه عصبی مصنوعی، حافظه کوتاه مدت ماندگار، شبکه عصبی پیچشی، پیش‌بینی قیمت



۱۶ اسفند ماه ۱۴۰۲



دانشگاه آزاد اسلامی واحد مراغه
با همکاری دبیرخانه برنامه‌های علمی استان کرمان برگزار می‌کند

دوین کنفرانس ملی تحولات نوین در مطالعات ملی اقتصادی و حسابداری

۲- مقدمه

تجزیه و تحلیل سری‌های زمانی مالی و پیش‌بینی ارزش‌های آتی قیمت سهام و حرکات آینده آنها، یک حوزه فعال در تحقیقات به مدت طولانی بوده است. در حالی که برخی از پژوهشگران به فرضیه بازار کارآمد اعتقاد دارند و ادعا می‌کنند که تخمین دقیق قیمت سهام امکان‌پذیر نیست، پیشنهاداتی در ادبیات وجود دارد که نشان می‌دهند می‌توان با استفاده از مدل‌های پیش‌بینی دقیق، ارزش‌های قیمت سهام را با سطح بسیار بالایی از دقت پیش‌بینی کرد. همچنین مشاهده شده است که دقت یک مدل پیش‌بینی به مجموعه متغیرهای استفاده شده در ساخت مدل، الگوریتم‌های استفاده شده و نحوه بهینه‌سازی مدل وابسته است. در ادبیات، پیشنهاداتی وجود دارد که بر روی تجزیه و تحلیل سری‌های زمانی برای پیش‌بینی قیمت سهام تمرکز دارند. در حال حاضر، تحلیل بنیادی سنتی و تحلیل تکنیکال هنوز رایج‌ترین روش‌های مورد استفاده برای بسیاری از سازمان‌ها و سرمایه‌گذاران فردی هستند. با توجه به بررسی ادبیات موضوع، شبکه‌های عصبی و یادگیری عمیق در پیش‌بینی قیمت سهام نقش بسیار مهمی ایفا می‌کنند. نتایج مطالعات انجام شده در این حوزه نشان می‌دهد که شبکه‌های عصبی و یادگیری عمیق با تجزیه و تحلیل دقیق داده‌های تاریخی و شاخص‌های مالی، می‌توانند پیش‌بینی‌های دقیقی در مورد قیمت سهام ارائه دهند. این دقت بالا به سرمایه‌گذاران کمک می‌کند تا تصمیم‌گیری‌های بهتری برای سرمایه‌گذاری خود بگیرند. پیش‌بینی و مدلسازی قیمت همواره امری پر چالش و جز جدایی‌ناپذیر تحلیل‌های سرمایه‌گذاران بوده، و از طرفی استفاده از شبکه‌های عصبی در امور مالی گسترشی روز افزون داشته است استفاده از مدل‌های مختلف شبکه‌ی عصبی، می‌تواند باعث ایجاد مدل‌های قدرتمند از هر لحاظ در این زمینه شود.

هدف از این پژوهش استفاده از دو شبکه‌ی عصبی پیچشی و حافظه کوتاه مدت ماندگار است، سوال و مسئله اصلی که در طول این پژوهش به دنبال پاسخ آن هستیم این است که شبکه‌های عصبی تا چه اندازه قابلیت پیش‌بینی قیمت در بازار بورس اوراق بهادار تهران دارند.

۲-۱- مبانی نظری تحقیق

الف) شبکه‌ی عصبی: شبکه‌های عصبی، همچنین به عنوان شبکه‌های عصبی مصنوعی (ANNs) شناخته می‌شوند، مدل‌های محاسباتی هستند که از ساختار و عملکرد مغز انسان الهام گرفته‌اند. آنها برای شناسایی الگوها و تفسیر داده‌ها طراحی شده‌اند، که این امر آنها را به عنوان یک جزء حیاتی از یادگیری ماشین و یادگیری عمیق می‌سازد. شبکه‌های عصبی برای اولین بار در سال ۱۹۴۴ توسط وارن مک‌کالو و والتر پیپس، دو پژوهشگر دانشگاه شیکاگو، پیشنهاد شد. آنها یک شبکه عصبی ساده را با استفاده از مدارهای الکتریکی مدل‌سازی کردند تا نشان دهند چگونه نورون‌ها در مغز ممکن است کار کنند. اولین شبکه عصبی قابل آموزش، پرسپترون، توسط روانشناس دانشگاه کارنل، فرانک روزنبلات، در سال ۱۹۵۷ نشان داده شد. در طول سال‌ها، شبکه‌های عصبی تکامل یافته و در زمینه‌های مختلف از تحقیقات علوم اعصاب تا هوش مصنوعی به کار گرفته شده‌اند.




۱۶ اسفند ماه ۱۴۰۲

دانشگاه آزاد اسلامی واحد مراغه
با همکاری دبیرخانه برنامه‌های علمی استان کرمان برگزار می‌کند



دوین کنفرانس ملی تحولات نوین در مباحثات ملی اقتصادی و حسابداری

Brain Neuron Structure



شکل ۱. شبکه عصبی بیولوژیکی

تعدادی از انواع شبکه‌های عصبی وجود دارند، هر کدام با معماری و کاربردهای خاص خود:

۱. شبکه‌های عصبی پیشرو (Feedforward Neural Networks): این انواع از ساده‌ترین شبکه‌های عصبی هستند. اطلاعات از چندین گره ورودی به سمت یک گره خروجی منتقل می‌شوند.
 ۲. شبکه‌های عصبی کانولوشنی (CNNs): این انواع به خصوص در بینایی کامپیوتری مفید هستند و در پردازش گفتار و تصویر نیز کاربردهایی دارند.
 ۳. شبکه‌های عصبی ماژولار (Modular Neural Networks): این انواع از چندین شبکه عصبی مختلف تشکیل شده‌اند که مستقل از یکدیگر کار می‌کنند و وظایف زیرگروهی مختلف را انجام می‌دهند.
 ۴. شبکه‌های عصبی بازگشتی (Recurrent Neural Network): این مدل پیچیده شبکه عصبی با ذخیره خروجی تولید شده توسط گره‌های پردازنده‌اش و بازگرداندن آنها به الگوریتم عمل می‌کند. این فرآیند امکان بهبود قابلیت‌های پیش‌بینی شبکه‌های عصبی مجازی را فراهم می‌کند.
 ۵. شبکه‌های عصبی بازپرازنده (Deconvolutional Neural Networks): بر اساس همان اصول شبکه‌های کانولوشنی عمل می‌کنند، با این تفاوت که عملیات به صورت برعکس اجرا می‌شود. این کاربرد خاص از هوش مصنوعی به هدف شناسایی سیگنال‌ها یا ویژگی‌های از دست رفته می‌پردازد که ممکن است در طول اجرای وظیفه اختصاص داده شده به شبکه عصبی کانولوشنی به عنوان غیرمهم شناخته شده باشند.
 ۶. شبکه‌های مولد مقابله‌ای (Generative Adversarial Networks): یک راهکار مدل‌سازی تولیدی هستند که از شبکه‌های عصبی کانولوشنی و سایر امکانات یادگیری عمیق برای اتوماسیون کشف الگوها در داده‌ها استفاده می‌کنند. مدل‌سازی تولیدی از یادگیری بدون نظارت استفاده می‌کند تا نتایج معقولی از یک مجموعه داده اصلی بسازد.
- هر نوع شبکه عصبی مزایا و معایب خود را دارد و انتخاب بین آنها به وظیفه خاص در دست استفاده بستگی دارد.




۱۶ اسفند ماه ۱۴۰۲

دانشگاه آزاد اسلامی واحد مراغه
با همکاری دبیرخانه برنامه‌های علمی استان کرمان برگزار می‌کند



دوبین کنفرانس ملی تحولات نوین در مطالعات ملی اقتصادی و حسابداری

Artificial Neural Network Architecture



شکل ۲. شبکه عصبی مصنوعی

(ب) شبکه‌ی عصبی پیچشی (CNN): شبکه‌های عصبی کانولوشنی (CNNs) یک نوع ویژه از مدل‌های شبکه عصبی هستند که اصولاً برای پردازش داده‌هایی با ساختار شبکه‌ای طراحی شده‌اند، مانند تصاویر. CNNs از فرایندهای بیولوژیکی در مغز انسان الهام گرفته‌اند، به خصوص از نحوه پردازش اطلاعات در قشر بصری مغز. آنها یکی از پایه‌های زیرمجموعه یادگیری عمیق از یادگیری ماشین هستند و به دلیل کارایی بالای خود در تشخیص الگوها و اشیاء در تصاویر و ویدئوها، زمینه بینایی کامپیوتر را ایجاد کرده‌اند.

شبکه‌های عصبی کانولوشنی (CNNs) از چند لایه تشکیل شده‌اند، هر کدام وظایف مختلفی را انجام می‌دهند:

۱. لایه کانولوشنی (Convolutional Layer): این لایه، سازه اصلی یک CNN است. لایه کانولوشنی یک مجموعه از فیلترهای قابل یادگیری را بر روی ورودی اعمال می‌کند. هر فیلتر ویژگی‌های خاصی از ورودی را فعال می‌کند، مانند لبه‌ها یا بافت‌ها، در مکان‌های فضایی مختلف. خروجی این لایه یک مجموعه از نقشه‌های ویژگی است.
۲. لایه استخراج (Pooling): پس از لایه کانولوشنی، لایه استخراج اندازه فضای نمایش را کاهش می‌دهد، تعداد پارامترها در شبکه را کاهش می‌دهد. این لایه همچنین در ایجاد تحمل به تغییرات مقیاس و جهت مشابهی برای ویژگی‌ها کمک می‌کند.
۳. لایه تابع فعال‌ساز: تابع فعال‌ساز یک فعال‌سازی غیرخطی اعمال می‌کند که غیرخطیت را به سیستم می‌آورد و به شبکه این امکان را می‌دهد که مسائل غیرخطی را حل کند. ReLU به عنوان یک تابع فعال‌ساز رایج است زیرا در حل مشکل کاهش گرادیان کمک می‌کند و امکان یادگیری سریع‌تر و بهتر را فراهم می‌کند.
۴. لایه کاملاً متصل: در انتها، CNNs یک یا چند لایه کاملاً متصل دارند. نورون‌های لایه کاملاً متصل اتصالات کاملی به همه فعال‌سازی‌های لایه قبلی دارند، همانند شبکه‌های عصبی معمولی. این لایه به طور اساسی یک حجم ورودی را (هرچه که خروجی از لایه‌های کانولوشنی یا استخراج باشد) دریافت می‌کند و یک بردار N-بعدی را خروجی می‌دهد که N تعداد کلاس‌هاست که برنامه برای شناسایی آنها طراحی شده است.




۱۶ اسفند ماه ۱۴۰۲

دانشگاه آزاد اسلامی واحد مراغه
با همکاری دبیرخانه برنامه‌های علمی استان کرمان برگزار می‌کند



دوین کنفرانس ملی تحولات نوین در مطالعات ملی اقتصادی و حسابداری



شکل ۳. شماتیک شبکه‌ی عصبی پیچشی

هرچند که شبکه‌های عصبی کانولوشنی (CNNs) به طور قابل توجهی زمینه‌بنایی کامپیوتر را پیشبرد داده‌اند، اما با چالش‌هایی همراه هستند. آموزش CNNs نیاز به حجم زیادی از داده‌های برچسب خورده، قدرت محاسباتی قابل توجه و گاهی ممکن است به مدل‌هایی منجر شود که به دلیل پیچیدگی و کمبود قابل فهم برای توضیح، به عنوان "جعبه‌های سیاه" در نظر گرفته می‌شوند. تحقیقات در حال انجام در این حوزه با هدف حل این چالش‌ها صورت می‌گیرد تا CNNs را کارآمدتر، قابل تفسیرتر و قابل یادگیری از داده‌های کمتر کند. در نتیجه، شبکه‌های عصبی کانولوشنی ابزاری قدرتمند در ابزارهای هوش مصنوعی و یادگیری ماشین هستند، به ویژه برای وظایف مرتبط با پردازش تصویر و ویدئو. قابلیت آنها برای یادگیری به طور خودکار و تطبیقی از سلسله مراتب فضایی از ویژگی‌ها باعث می‌شود که برای بسیاری از وظایف در حوزه بنیایی کامپیوتر باشند و پیشرفت‌های به‌روز در حال ادامه است که دامنه کاربرد آنها را در حوزه‌های مختلف گسترش می‌دهد.

ج) شبکه‌های حافظه کوتاه مدت ماندگار (LSTM): شبکه‌های حافظه کوتاه مدت ماندگار، به طور رایج با نام LSTMs شناخته می‌شوند، نوع خاصی از شبکه‌های عصبی بازگشتی (RNN) هستند که قادر به یادگیری وابستگی‌های بلند مدت هستند. این شبکه‌ها توسط هوخ‌رایتر و شمیدهوربر در سال ۱۹۹۷ معرفی شدند و از آن زمان به دلیل کارایی آنها در برنامه‌های مختلف، تصحیح و محبوبیت یافته‌اند. این شبکه‌ها اصطلاحاً برای یادگیری، پردازش و دسته‌بندی داده‌های توالی استفاده می‌شوند، زیرا این شبکه‌ها می‌توانند وابستگی‌های بلندمدت بین گام‌های زمانی را یاد بگیرند. آنها به ویژه در زمینه‌های تحلیل احساسات، مدل‌سازی زبان، تشخیص گفتار و تحلیل ویدئویی موثر هستند.

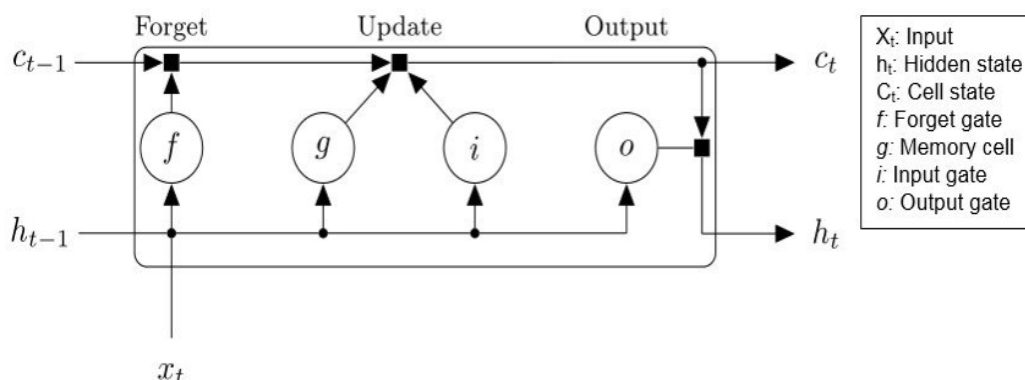
شبکه‌های حافظه کوتاه مدت ماندگار (LSTMs) دارای یک معماری منحصر به فرد هستند که شامل چندین جزء کلیدی است:

۱. حافظه سلول (Cell State): این بخش "حافظه" از LSTM است. این در امتداد تمام بلوک‌های لایه LSTM اجرا می‌شود و اطلاعات را از گام‌های زمانی اولیه به گام‌های بعدی منتقل می‌کند. همچنین می‌تواند اطلاعات را از طریق دروازه‌ها حذف یا اضافه کند.



دوین کنفرانس ملی تحولات نوین در مطالعات مالی اقتصادی و حسابداری

۲. دروازه‌ها (Gates): این شبکه‌ها دارای سه نوع دروازه هستند: دروازه فراموشی، دروازه ورودی و دروازه خروجی. این دروازه‌ها جریان اطلاعات ورودی و خروجی از حافظه را کنترل می‌کنند. آنها از توابع فعال‌سازی سیگموئید استفاده می‌کنند تا تصمیم بگیرند کدام اطلاعات را اجازه عبور دهند (ارزش‌های نزدیک به ۱) یا مسدود کنند (ارزش‌های نزدیک به ۰).
۳. دروازه فراموشی (Forget Gate): این دروازه تصمیم می‌گیرد کدام اطلاعات باید حذف یا نگه داشته شود. به ورودی فعلی و وضعیت پنهان قبلی نگاه می‌کند و برای هر عدد در حالت سلولی، یک عدد بین ۰ و ۱ را خروجی می‌دهد.
۴. دروازه ورودی (Input Gate): دروازه ورودی حافظه سلول را با اطلاعات جدید به‌روز می‌کند. این دارای دو بخش است: یک لایه سیگموئید که تصمیم می‌گیرد کدام ارزش‌ها را به‌روز کند و یک لایه \tanh که ارزش‌های کاندید جدیدی ایجاد می‌کند که می‌توانند به حالت اضافه شوند.
۵. دروازه خروجی (Output Gate): دروازه خروجی تصمیم می‌گیرد که وضعیت پنهان بعدی چه باشد. وضعیت پنهان حاوی اطلاعاتی در مورد ورودی‌های گذشته است. دروازه خروجی به ورودی فعلی و حالت جدید سلول برای تعیین خروجی خود نگاه می‌کند.



شکل ۴. شماییک شبکه عصبی حافظه کوتاه مدت ماندگار

LSTMs مناسب برای وظایف پیش‌بینی دنباله و در ثبت وابستگی‌های بلندمدت عالی عمل می‌کنند. کاربردهای آنها در وظایف مربوط به دنباله‌ها و سری‌ها گسترده است. آنها به خصوص در زمینه‌های ترجمه ماشینی، تشخیص گفتار، تحلیل احساسات، مدل‌سازی زبان، و تحلیل ویدیویی بسیار مؤثر هستند.

۲-۲- پیشینه تحقیق

ژیان کائو و همکاران (۲۰۱۹) طی مقاله‌ای تحت عنوان «مدل پیش‌بینی سری زمانی مالی بر اساس LSTM-CEEMDAN» بر روی چهار شاخص DAX، HSI، S&P500 و SSE بوده و از قیمت بسته شدن روزانه برای پیش‌بینی استفاده شده است. نتایج این مدل ترکیبی نشان می‌دهد که خطای بدست آمده از این مدل براساس توابع MAE، MAPE، RMSE نسبت به مدل‌های LSTM، SVM CEEMDAN-SVM، CEEMDAN-MLP عدد کمتری را نشان می‌دهد. همچنین این مدل قابلیت بهینه تر شدن را دارد چرا که برای ورودی فقط از قیمت بسته شدن استفاده شده است در حالیکه می‌توان تعداد ورودی‌ها را افزایش داد و از بالاترین قیمت و



دوین کنفرانس ملی تحولات نوین در مطالعات مالی اقتصادی و حسابداری

پایین‌ترین قیمت و حجم معاملات و سایر ویژگی‌های قیمت استفاده کرد (Li Jian, Li Zhi, Cao Jian, ۲۰۱۹). عمار خار و همکاران (۲۰۱۷) طی مقاله تحت عنوان "پیش بینی کوتاه مدت قیمت سهام با استفاده از یادگیری عمیق" با استفاده از داده‌های یک ساله ۱۰ شرکت از بورس اوراق بهادار نیویورک که بصورت دقیقه‌ای (تایم فریم یک دقیقه) انتخاب شده و سپس نرمال سازی انجام شده است تا داده‌ها بین صفر و یک قرار بگیرند. در این مقاله از دو نوع شبکه عصبی استفاده شده است یک شبکه عصبی پیش خور با عنوان شبکه‌ی عصبی چند لایه پرسپترون و یک شبکه عصبی بازگشتی با عنوان شبکه عصبی کوتاه مدت ماندگار. برای مقایسه این دو مدل از معیار خطای میانگین مربعات ریشه استفاده شده است و نتایج نشان می‌دهد که مدل شبکه‌ی عصبی چندلایه پرسپترون عملکرد بهتری داشته است. چی یو لی و همکاران (۲۰۱۷) طی مقاله‌ای تحت عنوان «پیش بینی قیمت سهام با اخبار مالی مبتنی بر شبکه‌های عصبی پیچشی بازگشتی» از ترکیب یک شبکه عصبی پیچشی و یک شبکه عصبی کوتاه مدت ماندگار و الگوریتم تبدیل کلمه به بردار استفاده می‌کنند، همچنین داده‌های ورودی قیمت‌ها تاریخی و عناوین اخبار آن سهم می‌باشد، نتایج بدست آمده نشان می‌دهد که مدل ترکیبی از مدل شبکه‌ی عصبی کوتاه مدت ماندگار عملکرد بهتری دارد (C. -Y. Lee and V. -W. Soo, ۲۰۱۷). هیرانشا و همکاران (۲۰۱۸) طی مقاله‌ای تحت عنوان «پیش بینی بازار سهام هند با استفاده از مدل‌های یادگیری عمیق» با استفاده از چهار نوع معماری یادگیری عمیق یعنی CNN, LSTM, RNN, MLP نسبت به پیش بینی قیمت سهام از دو بازار مختلف هند و آمریکا اقدام می‌کنند، به گونه‌ای که مدل‌ها بر اساس سهام شرکتی از هند آموزش داده می‌شود و پنج شرکت مختلف از دو بازار هند و آمریکا پیش بینی می‌شود. و نتایج نشان می‌دهد که مدل CNN از سایر مدل‌ها عملکرد بهتری در این روش داشته است (Gopalakrishnan E.A, Hiransha M, ۲۰۱۸). سیدرا مهتاب و همکاران (۲۰۲۱) طی مقاله‌ای با عنوان «پیش‌بینی قیمت سهام با استفاده از یادگیری ماشین و مدل‌های یادگیری عمیق مبتنی بر LSTM» برای هدف مطالعه این پژوهش، از مقادیر شاخص NIFTY 50 بورس ملی هند (NSE) در دوره زمانی ۲۹ دسامبر ۲۰۱۴ تا ۳۱ ژوئیه ۲۰۲۰ استفاده شده است. چارچوب پیش‌بینی در این پژوهش ساخت چهار مدل رگرسیون مبتنی بر یادگیری عمیق با استفاده از شبکه‌های حافظه بلندمدت و کوتاه‌مدت (LSTM) با رویکرد جدید walk-forward validation می‌باشد. از قدرت مدل‌های رگرسیون LSTM در پیش‌بینی مقادیر قیمت باز شدن NIFTY 50 در آینده با استفاده از چهار مدل مختلف استفاده می‌کنیم که در معماری و ساختار داده‌های ورودی متفاوت هستند. نتایج به وضوح نشان می‌دهد که مدل تک متغیره مبتنی بر LSTM که از داده‌های یک هفته قبل به عنوان ورودی برای پیش‌بینی ارزش قیمت باز شدن هفته آینده سری زمانی NIFTY 50 استفاده می‌کند دقیق‌ترین مدل است (Sidra Mehtab, Jaydip Sen, Abhishek Dutta, ۲۰۲۰). ژائو وو و همکاران (۲۰۲۱) طی مقاله با عنوان «یک مدل ترکیبی ادغام یادگیری عمیق با تحلیل احساسات سرمایه گذار برای پیش بینی قیمت سهام» یک مدل ترکیبی ارائه می‌کنند که رویکرد یادگیری عمیق را با یک مدل تحلیل احساسات برای پیش‌بینی قیمت سهام ترکیب می‌کند. از یک مدل شبکه عصبی پیچشی برای طبقه بندی احساسات پنهان سرمایه گذاران استفاده شده است که از یک انجمن بزرگ سهام استخراج می‌شود. سپس یک مدل تحقیقاتی ترکیبی را با استفاده از رویکرد شبکه عصبی LSTM برای تجزیه و تحلیل شاخص‌های فنی از بازار سهام و نتایج تحلیل احساسات ارائه شده است. علاوه بر این کار، آزمایش‌های واقعی را از شش صنعت کلیدی در سه بازه زمانی در بورس اوراق بهادار شانگهای (SSE) انجام داده است تا اثربخشی و کاربرد مدل پیشنهادی را تأیید کند. نتایج آزمایش نشان می‌دهد که مدل پیشنهادی نسبت به طبقه‌بندی‌کننده‌های پایه در طبقه‌بندی احساسات سرمایه‌گذار به عملکرد بهتری دست یافته است و این رویکرد ترکیبی در پیش‌بینی قیمت سهام در مقایسه با مدل واحد و مدل‌های بدون تحلیل احساسات عملکرد بهتری دارد.



۱۶ اسفند ماه ۱۴۰۲



دوبین کنفرانس ملی تحولات نوین در مطالعات ملی اقتصادی و حسابداری

۳- روش تحقیق

هدف اصلی این پژوهش پیش بینی قیمت سهام با استفاده از دو نوع شبکه عصبی در بازار بورس تهران است. این مدل‌ها را از منظر دقت پیش‌بینی کنندگی به طور مطلق و نسبی بررسی می‌کنیم.

جامعه آماری این پژوهش بورس اوراق بهادار تهران می‌باشد. حجم نمونه آماری این پژوهش داده‌های سه نماد بورس اوراق بهادار تهران به شرح ایرانخودرو، البرز دارو و توسعه معادن روی ایران می‌باشد. در این پژوهش از هشت ویژگی قیمت در چارچوب زمانی روزانه از تاریخ ۱۳۸۰ تا تاریخ ۱۴۰۰ استفاده می‌شود که شامل بالاترین قیمت، پایین‌ترین قیمت، قیمت بسته شدن (آخرین معامله)، قیمت باز شدن (اولین معامله)، ارزش معاملات، حجم معاملات، اختلاف قیمت بسته شدن دو روز متوالی، درصد تغییرات قیمت بسته شدن دو روز متوالی. نمونه گیری به صورت غیر تصادفی بوده است. تعداد زیاد داده‌ها نیز به دلیل نیاز مدل‌های یادگیری عمیق به تعداد داده‌های زیاد و عدم وجود گپ قیمتی و زمانی هم به دلیل پیوستگی در داده‌ها در نظر گرفته شده است. اطلاعات و داده‌های مربوط به پژوهش از طریق سایت ره آورد نوین بدست آمده است.

فرآیند انجام پژوهش بدین صورت است که در مرحله اول بعد از ورود داده‌ها، تغییر مقیاس داده‌ها است که می‌توان به دو روش نرمالسازی و استاندارد سازی انجام داد که در این پژوهش از روش استاندارد سازی استفاده شده است. علت استفاده از این روش وجود ویژگی‌هایی با واحدهای غیر یکسان می‌باشد. روش نرمال سازی^۱: مقیاس‌بندی Min-Max یا Min-Max Scaler یکی از روش‌های رایج در نرمال‌سازی داده‌ها است که به منظور تغییر مقیاس داده‌ها به بازه‌ای مشخص میان دو مقدار حداقل و حداکثر انجام می‌شود. این روش باعث می‌شود تمام داده‌ها به بازه‌ای مشخصی مثل [۰, ۱] تغییر مقیاس یابند. روش استانداردسازی^۲: استانداردسازی یکی دیگر از روش‌های نرمال‌سازی داده‌هاست که به منظور تبدیل داده‌ها به یک توزیع با میانگین صفر و واریانس یک انجام می‌شود. در این روش، از میانگین و واریانس داده‌ها برای تغییر مقیاس و تبدیل واحدهای داده‌ها استفاده می‌شود. این کار به مدل‌های یادگیری ماشینی کمک می‌کند که بهتر و با دقت‌تر با داده‌ها برخورد کنند.

مرحله دوم این است که داده را به دو دسته آموزش^۳ و آزمون^۴ تقسیم کنیم. در این پژوهش در هر سه مدل، ۸۰ درصد داده را به عنوان داده‌های آموزش و ۲۰ درصد داده‌ها را به عنوان داده‌های آزمون فرض می‌کنیم. به علت محدود تعداد داده‌ها، از داده‌های آزمون، در ارزیابی عملکرد مدل نیز استفاده شده است. مرحله سوم، تبدیل داده‌های سری زمانی به فرمت نظارت شده است. تبدیل داده‌های سری زمانی به فرمت نظارت شده^۵، یک مرحله مهم برای استفاده از مدل‌های رگرسیونی در پیش‌بینی و تحلیل داده‌های سری زمانی است. در این فرمت، داده‌های سری زمانی به صورت جفت‌های ورودی و خروجی مرتبط تبدیل می‌شوند. به عبارت دیگر، از نمونه‌های گذشته برای پیش‌بینی مقدار در زمان آینده استفاده می‌شود. در این پژوهش برای تبدیل داده‌ها از سری زمانی به داده‌های نظارت شده از دستور زیر استفاده می‌کنیم. این کار معمولاً با استفاده از پنجره‌های زمانی (time_step) ویژگی‌های قبلی به عنوان ورودی و مقدار زمان بعدی به عنوان خروجی انجام می‌شود. ابتدا گام زمانی (time_step) را مشخص می‌کنیم. گام زمانی مشخص می‌کند که برای پیش‌بینی مقدار

1. MinMaxScaler

2. Standardization

3. Train

4. Test

5. Supervised



۱۶ اسفند ماه ۱۴۰۲




دوین کنفرانس ملی تحولات نوین در مطالعات ملی اقتصادی و حسابداری

برچسب گذاری از چند گام زمانی قبل استفاده کنیم. در اینجا از گام زمانی ۲۲ استفاده شده است که برابر یک ماه کاری می‌باشد. در ادامه ماتریس‌های x_{train} و y_{train} و x_{test} و y_{test} را تشکیل می‌دهیم. مرحله چهارم برازش و ارزیابی مدل است. برازش مدل^۶ یعنی تطابق مدل با داده‌های آموزشی. این تطابق می‌تواند به سه صورت مختلف اتفاق بیفتد: برازش خوب^۷، بیش برازش^۸ و کم برازش^۹. این سه وضعیت به کیفیت آموزش مدل نسبت به داده‌های آموزشی و داده‌های جدید اشاره دارند. در نهایت برای رفع بیش برازش از روش Elastic Net استفاده شده است. این روش از ترکیب دو روش Lasso و Ridge بدست می‌آید. روش Lasso نسبت به داده‌های پرت حساسیت زیادی ندارد، و همچنین بعضی از وزن‌ها را به صفر کاهش می‌دهد ولی ممکن است که بعضی وزن‌ها همچنان بزرگ باقی بمانند، اما در مدل Ridge که نسبت به داده‌های پرت حساسیت بیشتری دارد، وزن‌ها را کوچک می‌کند ولی هیچگاه صفر نمی‌شوند. مقادیر لانداها بصورت تجربی و آزمون و خطا بدست آمده است.

۱-۳- ارزیابی پژوهش


برای ارزیابی و سنجش میزان خطا بین مقدار واقعی و مقدار پیش‌بینی شده از سه معیار خطای میانگین خطای مطلق^{۱۰}، ریشه میانگین مربعات خطا^{۱۱} و ضریب تعیین^{۱۲} استفاده شده است. خطای میانگین مطلق یک معیار اندازه‌گیری است که در زمینه‌های مختلف، به ویژه در آمار و یادگیری ماشین، برای اندازه‌گیری میزان تفاوت بین مقادیر پیش‌بینی شده و مقادیر واقعی یک متغیر استفاده می‌شود. خطای میانگین مطلق در مقابل خطاهای بزرگ و پرت حساسیت کمتری دارد. این به این معناست که اگر تعدادی از پیش‌بینی‌ها خطا داشته باشند، خطای میانگین مطلق کمتر تحت تأثیر قرار می‌گیرد و مقدار کمی تغییر می‌کند. خطای میانگین مطلق به سادگی قابل تفسیر است.

رابطه  نحوه محاسبه خطای میانگین مطلق را نشان می‌دهد.

$$MAE = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - ty_i|$$

رابطه 

ریشه میانگین مربعات خطا نیز مانند خطای میانگین مطلق، یک معیار اندازه‌گیری می‌باشد که در زمینه‌های مختلف از جمله آمار و یادگیری ماشین، برای اندازه‌گیری میزان تفاوت بین مقادیر پیش‌بینی شده و مقادیر واقعی یک متغیر استفاده می‌شود. این معیار مختصراً ریشه میانگین مربعات خطا نامیده می‌شود. به عنوان معیاری که تفاوت‌ها را به صورت مربعی محاسبه می‌کند، ریشه میانگین مربعات خطا به خطاهای بزرگتر و کوچکتر اهمیت می‌دهد. این معنایی از دقت در پیش‌بینی دارد که میزان تفاوت‌ها، حتی اگر کوچک باشند، در نهایت تأثیر خود را بر نتایج دارند. در مواجهه با خطاهای بزرگتر، ریشه میانگین مربعات خطا اهمیت بیشتری از خطای میانگین مطلق به آنها اختصاص می‌دهد.

رابطه  نحوه محاسبه ریشه میانگین مربعات خطا را نشان می‌دهد.

۶. Model Fitting

۷. Goodfit

۸. Overfitting

۹. Underfitting

۱۰. Mean absolute error

۱۱. Root mean square error

۱۲. R- squared



۱۶ اسفند ماه ۱۴۰۲



دوین کنفرانس ملی تحولات نوین در مطالعات ملی اقتصادی و حسابداری

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2} \quad \text{رابطه (۳۳)}$$

ضریب تعیین، معیاری است که میزان تفسیر متغیر وابسته توسط متغیرهای مستقل در یک مدل را اندازه‌گیری می‌کند. این معیار معمولاً در آمار و یادگیری ماشین استفاده می‌شود تا نشان دهد که مدل چه مقدار از تغییرات متغیر وابسته را توسط متغیرهای مستقل توجیه می‌کند. ضریب تعیین معادل میانگین مربعات ضریب همبستگی بین متغیر وابسته و متغیرهای مستقل است. در واقع، ضریب تعیین نشان می‌دهد که چه مقدار از تغییرات متغیر وابسته توسط تغییرات متغیرهای مستقل توجیه می‌شود. مقدار ضریب تعیین بین ۰ تا ۱ قرار می‌گیرد، که ۰ به معنای عدم توجیه تغییرات متغیر وابسته توسط متغیرهای مستقل است و ۱ به معنای توجیه کامل تغییرات است. مقدار ضریب تعیین به شما ایده می‌دهد که مدل شما چه مقدار از تغییرات واقعی را توجیه می‌کند. اگر مقدار ضریب تعیین بالا باشد، این نشان می‌دهد که مدل‌تان با داده‌ها به خوبی مطابقت دارد.

رابطه (۳۴) نحوه محاسبه ضریب تعیین را نشان می‌دهد.

$$R^2 = 1 - \frac{(\sum_{i=1}^n (y_i - \hat{y}_i)^2)/n}{(\sum_{i=1}^n (y_i - \bar{y})^2)/n} \quad \text{رابطه (۳۴)}$$

۴- یافته‌های پژوهش

در جدول ۱ نتایج و عملکرد هر دو مدل در هر سه شرکت قابل مشاهده است. نتایج حاصل از معیارهای ارزیابی نشان می‌دهد که عملکرد مدل‌ها چگونه بوده است. نتایج نشان می‌دهد که مدل شبکه عصبی پیچشی توانایی پیش‌بینی با دقت خوبی را دارا می‌باشند. شبکه‌های عصبی بازگشتی از بهترین نوع شبکه‌ها برای پیش‌بینی قیمت هستند، اما نتایج نشان می‌دهد که شبکه عصبی پیچشی عملکرد بهتری از شبکه عصبی حافظه کوتاه مدت ماندگار داشته است.

جدول ۱. عملکرد مدل‌ها

نماد	مدل	<i>R_square</i>	<i>MAE</i>	<i>RMSE</i>
ایران خودرو	CNN	۹۶.۰۵%	۱۵۲	۴۸۵
ایران خودرو	LSTM	۹۴.۱۰%	۳۰۴	۵۹۲
البرز دارو	CNN	97.۲۴%	۶۹۶	۱۲۷۶
البرز دارو	LSTM	8۰.۶۳%	۱۶۹۴	۳۳۸۱
توسعه معادن روی	CNN	97.00%	۱۴۴۷	۲۶۰۴
توسعه معادن روی	LSTM	۷۹.۵۳%	۲۹۰۳	۶۴۳۲



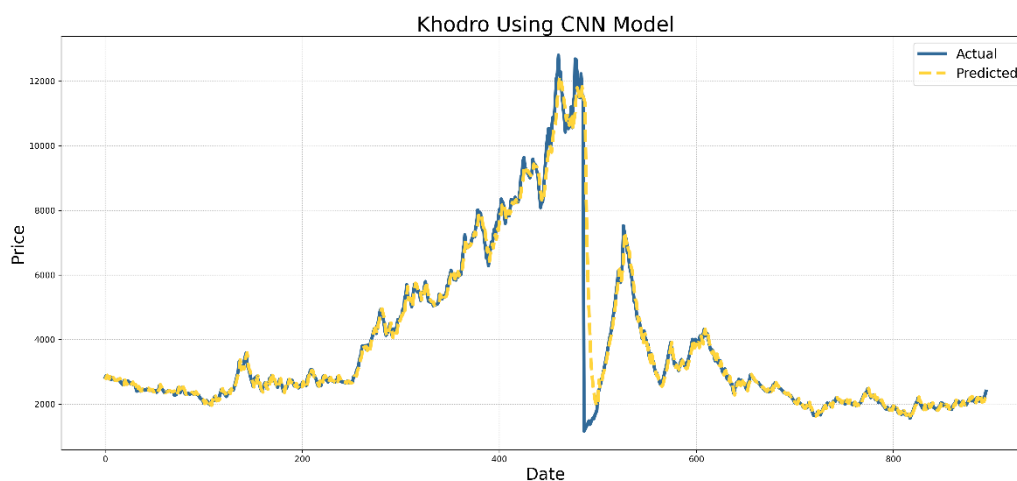
۱۶ اسفند ماه ۱۴۰۲

دانشگاه آزاد اسلامی واحد مراغه
با همکاری دبیرخانه برنامه‌های علمی استان کرمان برگزار می‌کند




دومین کنفرانس ملی تحولات نوین در مدل‌های اقتصادی و حسابداری

نتایج عملکرد مدل‌ها در شکل‌های  تا  قابل مشاهده است.



شکل ۲. نمودار شرکت ایرانخودرو (مدل CNN)



شکل ۳. نمودار شرکت ایرانخودرو (مدل LSTM)




۱۶ اسفند ماه ۱۴۰۲


دانشگاه آزاد اسلامی واحد مراغه
با همکاری دبیرخانه برنامه‌های علمی استان کرمان برگزار می‌کند



دومین کنفرانس ملی تحولات نوین در مطالعات مالی اقتصادی و حسابداری



شکل ۴. نمودار شرکت البرز دارو (مدل CNN)



شکل ۵. نمودار شرکت البرز دارو (مدل LSTM)




۱۶ اسفند ماه ۱۴۰۲


دانشگاه آزاد اسلامی واحد مراغه
با همکاری دبیرخانه برنامه‌های علمی استان کرمان برگزار می‌کند



دومین کنفرانس ملی تحولات نوین در مطالعات ملی اقتصادی و حسابداری



شکل ۶. نمودار شرکت توسعه معادن روی ایران (مدل CNN)



شکل ۷. نمودار شرکت توسعه معادن روی ایران (مدل LSTM)

با بررسی نتایج که در جدول ۱ و تصاویر ۵ تا ۱۰ گزارش شده است نشان می‌دهد که مدل شبکه عصبی حافظه کوتاه مدت ماندگار برعکس مدل شبکه عصبی پیچشی عملکرد قابل قبول ندارد. با توجه به این که این دو مدل در شرایط یکسان بررسی شده اند می‌توان نتیجه گرفت که مدل شبکه عصبی پیچشی با پیکربندی یکسانی که در این پژوهش انجام شده است عملکرد بهتری نسبت مدل شبکه عصبی حافظه کوتاه مدت ماندگار داشته است. البته عوامل بسیاری در دقت پیش بینی کنندگی مدل‌ها اثر گذار است که در اینجا می‌توان به میزان پیچیدگی مدل از نظر تعداد واحد و فیلتر و همچنین تعداد لایه و تعداد متغیرهای مستقل اشاره کرد.



۱۶ اسفند ماه ۱۴۰۲



دانشگاه آزاد اسلامی واحد مراغه
با همکاری دبیرخانه برنامه‌های علمی استان کرمان برگزار می‌کند

دومین کنفرانس ملی تحولات نوین در مطالعات مالی اقتصادی و حسابداری

۵- بحث و نتیجه‌گیری

با توجه به پیشرفت روز افزون مدل‌های یادگیری عمیق در پیش‌بینی داده‌های مختلف از جمله داده‌های مالی، تلاش کرده‌ایم در این پژوهش به بررسی برخی از مدل‌های یادگیری عمیق برای تخمین و پیش‌بینی در بورس اوراق بهادار تهران بپردازیم. با توجه به محدودیت‌ها و ویژگی‌های خاص بورس اوراق بهادار تهران، مانند دامنه نوسان، موجب ایجاد علاقه در محققان جهت بررسی و پیش‌بینی این بازار با استفاده از مدل‌های یادگیری ماشین و یادگیری عمیق می‌شود. نتایجی که یافته‌های این پژوهش نشان می‌دهد، این است که مدل‌های یادگیری عمیق در صورتی که در انتخاب ویژگی‌هایی (متغیرهای مستقل) که بتوانند بیشترین میزان معناداری را در تفسیر علل فراز و فرودهای قیمت را دوره‌های رونق و رکود بازار بیان کند، قابلیت و توانایی پیش‌بینی قیمت، با دقت قابل قبول دارا می‌باشند.

برای پژوهش‌های آینده می‌توان مدل ترکیبی حاصل از این دو مدل مورد استفاده در این پژوهش را مورد بررسی قرار داد. همچنین با توجه به اینکه در این پژوهش صرفاً از داده‌های گذشته‌نگر و فنی استفاده شده است می‌توان از داده‌های موثر دیگر بر بازار سرمایه مانند داده‌های بنیادی و کلان مانند نرخ اوراق منتشره در بازار بدهی و نرخ بهره سیاستی استفاده کرد.

۶- منابع

- Vanaga, R., & Sloka, B. (2020). Financial and capital market commission financing: aspects and challenges. *Journal of Logistics, Informatics and Service Science*, 7(1), 17–30.
- Zhang, L., & Kim, H. (2020). The influence of financial service characteristics on use intention through customer satisfaction with mobile fintech. *Journal of System and Management Sciences*, 10(2), 82–94.
- Badea, L., Ionescu, V., & Guzun, A.-A. (2019). What is the causal relationship between Stoxx Europe 600 sectors? But between large firms and small firms? *Economic Computation And Economic Cybernetics Studies And Research*, 53(3), 5–20.
- Sousa, J., Montevechi, J., & Miranda, R. (2019). Economic lot-size using machine learning, parallelism, metaheuristic and simulation. *Journal of Logistics, Informatics and Service Science*, 18(2), 205–216.
- Coser, A., Maer-Matei, M. M., & Albu, C. (2019). Predictive models for loan default risk assessment. *Economic Computation And Economic Cybernetics Studies And Research*, 53(2), 149–165.
- Qiao, R. (2019). Stock prediction model based on neural network. *Operations Research and Management Science*, 28(10), 132–140.
- Jung, C., & Boyd, R. (1996). Forecasting UK stock prices. *Applied Financial Economics*, 6(3), 279–286.
- Bleesser, W., & Liicoff, P. (2005). Predicting stock returns with Bayesian vector autoregressive. *Data Analysis, Machine Learning and Applications*, 1, 499–506.
- Adebiyi, A., Adewumi, A., & Ayo, C. (2014). Stock price prediction using the ARIMA model. In *Proceedings of the 2014 UKSim-AMSS 16th International Conference on Computer Modelling and Simulation*. IEEE, Cambridge, UK.
- Zhang, C., Cheng, X., & Wang, M. (2005). An empirical research in the stock market of Shanghai by GARCH model. *Operations Research and Management Science*, 4, 144–146.



۱۶ اسفند ماه ۱۴۰۲



دانشگاه آزاد اسلامی واحد مراغه
با همکاری دبیرخانه برنامه‌های علمی استان کرمان برگزار می‌کند

دومین کنفرانس ملی تحولات نوین در مباحثات ملی اقتصادی و حسابداری

Yang, Q., & Wang, C. (2019). A study on forecast of global stock indices based on deep LSTM neural network. Statistical Research, 36(6), 65–77.

Moon, K.-S., & Kim, H. (2019). Performance of deep learning in prediction of stock market volatility. Economic Computation And Economic Cybernetics Studies And Research, 53(2), 77–92.

Li, J., Pan, S., Huang, L., & Zhu, X. (2019). A machine learning based method for customer behavior prediction. Tehnicki Vjesnik-Technical Gazette, 26(6), 1670–1676.

White, H. (1988). Economic prediction using neural networks: the case of IBM daily stock returns. Earth Surface Processes & Landforms, 8(5), 409–422.

Zhang, G. P. (2003). Time series forecasting using a hybrid ARIMA and neural network model. Neurocomputing, 50(1), 159–175.

Sun, Y., Liang, Y., & Zhang, W. (2005). Optimal partition algorithm of the RBF neural network and its application to financial time series forecasting. Neural Computing and Applications, 14, 1441–1449.

Adhikari, R., & Agrawal, R. (2014). A combination of artificial neural network and random walk models for financial time series forecasting. Neural Computing and Applications, 24, 305–315.

Zhang, L., Wang, F., Xu, B., Chi, W., Wang, Q., & Sun, T. (2018). Prediction of stock prices based on LM-BP neural network and the estimation of overfitting point by RDCI. Neural Computing and Applications, 30(5), 1425–1444.

Hu, Y. (2018). Stock market timing model based on convolutional neural network – a case study of Shanghai composite index. Finance & Economy, 4, 71–74.

Alibasic, E., Fazo, B., & Petrovic, I. (2019). A new approach to calculating electrical energy losses on power lines with a new improved three-mode method. Tehnicki Vjesnik-Technical Gazette, 26(2), 405–411.

Xue, Y., Wang, C., & Miao, C. (2020). Research on financial assets transaction prediction model based on LSTM neural network. Neural Computing and Applications, 1.

LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. Proceedings of the IEEE, 86(11), 2278–2324.

Kim, B. S., & Kim, T. G. (2019). Cooperation of simulation and data model for performance analysis of complex systems. International Journal of Simulation Modelling, 18(4), 608–619.

Qin, L., Yu, N., & Zhao, D. (2018). Applying the convolutional neural network deep learning technology to behavioural recognition in intelligent video. Tehnicki Vjesnik-Technical Gazette, 25(2), 528–535.

Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. MIT Press, 9(8), 1735–1780.

Ta, V.-D., Liu, C.-M., & Tadesse, D. A. (2020). Portfolio optimization-based stock prediction using long-short term memory network in quantitative trading. Applied Sciences, 10(2), 437–457.



۱۶ اسفند ماه ۱۴۰۲



دانشگاه آزاد اسلامی واحد مراغه
با همکاری دبیرخانه برنامه‌های علمی استان کرمان برگزار می‌کند

دومین کنفرانس ملی تحولات نوین در مباحثات ملی اقتصادی و حسابداری

- Zarrad, O., Hajjaji, M. A., & Mansouri, M. N. (2019). Hardware implementation of hybrid wind-solar energy system for pumping water based on artificial neural network controller. *Studies in Informatics and Control*, 28(1), 35–44.
- Saric, T., Simunovic, G., Vukelic, D., Simunovic, K., & Lujic, R. (2018). Estimation of CNC grinding process parameters using different neural networks. *Tehnicki Vjesnik-Technical Gazette*, 25(6), 1770–1775.
- Gupta, N., & Jalal, A. (2019). Integration of textual cues for fine-grained image captioning using deep CNN and LSTM. *Neural Computing and Applications*, 12, 1–10.
- Yadav, A., Jha, C. K., & Sharan, A. (2020). Optimizing LSTM for time series prediction in Indian stock market. *Procedia Computer Science*, 167, 2091–2100.
- Kim, H. Y., & Won, C. H. (2018). Forecasting the volatility of stock price index: a hybrid model integrating LSTM with multiple GARCH-type models. *Expert Systems with Applications*, 103, 25–37.
- Petersen, N. C., Rodrigues, F., & Pereira, F. C. (2019). Multi-output bus travel time prediction with convolutional LSTM neural network. *Expert Systems with Applications*, 120, 426–435.
- Jin, Z., Yang, Y., & Liu, Y. (2020). Stock closing price prediction based on sentiment analysis and LSTM. *Neural Computing and Applications*, 32(13), 9713–9729.
- Svetlana, B., & Ioannis, T. (2019). An ensemble of LSTM neural networks for high-frequency stock market classification. *Journal of Forecasting*, 38(6), 600–619.



۱۶ اسفند ماه ۱۴۰۲



دانشگاه آزاد اسلامی واحد مراغه
با همکاری دبیرخانه برنامه‌های علمی استان کرمان برگزار می‌کند

دوبین کنفرانس ملی تحولات نوین در مطالعات مالی اقتصادی و حسابداری

Stock price forecasting in Tehran stock market with artificial intelligence approach

Mostafa Shaygani

Master of Financial Management, Faculty of Management and Accounting, Farabi Colleges of Tehran University, Qom, Iran

shaygani@ut.ac.ir

Asgar Noorbakhsh

Assistant Professor, Department of Financial Management, Faculty of Management and Accounting, Farabi Campus, University of Tehran, Qom, Iran

anoorbakhsh@ut.ac.ir

Abstract

Background and Objective: The main objective of this research is to predict stock prices using two types of neural networks in the Tehran Stock Exchange market. We examine these models in terms of absolute and relative predictive accuracy. Given that recurrent neural networks generally have good capabilities in predicting time series data, while convolutional neural networks are primarily used for applications such as computer vision.

Research Method: Python language in the VS Code editor has been used to conduct this research. The statistical population of this research is the Tehran Stock Exchange. The sample size of this research includes data from three symbols of the Tehran Stock Exchange, namely Iran Khodro, Alborz Darou, and Tosee Maa'dan Rou Iran. In this research, eight price features are used within the daily timeframe from 2001 to 2022, including the highest price, lowest price, closing price, opening price, transaction value, transaction volume, the difference in closing price between two consecutive days, and daily return. Three metrics of mean absolute error, root mean square error, and coefficient of determination have been used to evaluate the models' performance.

Findings: The results indicate that the convolutional neural network model has the ability to predict with good accuracy. Recurrent neural networks are among the best types of networks for price prediction, but the results show that the convolutional neural network has performed better than the short-term memory neural network.



۱۶ اسفند ماه ۱۴۰۲



دانشگاه آزاد اسلامی واحد مراغه
با همکاری دبیرخانه برنامه‌های علمی استان کرمان برگزار می‌کند

دومین کنفرانس ملی تحولات نوین در مطالعات مالی اقتصادی و حسابداری

Conclusion: The results of this research suggest that deep learning models, when selecting features (independent variables) that can express the highest level of significance in interpreting the causes of price fluctuations during market booms and recessions, have the ability and capability to predict prices with acceptable accuracy.

Keywords: Artificial Neural Network, Short-Term Memory, Convolutional Neural Network, Price Prediction